

Documentação - Painel de Análise de Sobrevivência Oncológica

1 Introdução

Este documento descreve o processo de tratamento e filtragem de dados oncológicos que são utilizados no Painel de Análise de Sobrevivência Oncológica. As análises podem ser acessadas através do painel disponível em: https://esleycaminhasferreira.shinyapps.io/painel_sobrevivencia/.

2 Sobre os dados

Os dados utilizados foram obtidos a partir do arquivo `pacigeral.dbf`, proveniente da Fundação Oncocentro de São Paulo (FOSP), instituição de referência vinculada à Secretaria de Estado de São Paulo. A FOSP é uma das principais fontes de dados oncológicos no Brasil, mantendo registros hospitalares de grande relevância para a pesquisa e o desenvolvimento de políticas públicas de combate ao câncer no país.

Foram incluídas neoplasias das seguintes categorias:

- C50: Mama
- C51-C58: Órgãos genitais femininos
- C60-C63: Órgãos genitais masculinos
- C64-C68: Trato urinário
- C69-C72: Olho, cérebro e SNC
- C73-C75: Tiróide e outras glândulas
- C76: Outras localizações mal definidas
- C77: Linfonodos
- C80: Localização primária desconhecida

3 Pré-processamento dos dados

Variáveis da base `pacigeral.dbf` que foram utilizadas:

- TOPOGRUP: Grupo da topografia (C50-C80)
- SEXO: Sexo do paciente (1-Masculino, 2-Feminino)
- IDADE: Idade do paciente em anos
- FAIXAETAR: Faixa etária do paciente
- EC: Estádio clínico (classificação TNM)
- ULTINFO: Última informação sobre o paciente
- TRATAMENTO: Código de combinação dos tratamentos realizados
- DTCONSULT: Data da 1ª consulta
- DTDIAG: Data do diagnóstico
- DTTRAT: Data de início do tratamento
- DTULTINFO: Data da última informação do paciente

Variáveis criadas durante o pré-processamento:

- CONSDIAG: Diferença em dias entre consulta e diagnóstico
- TRATCONS: Diferença em dias entre consulta e tratamento
- DIAGTRAT: Diferença em dias entre diagnóstico e tratamento
- TEMPO_OBS_: Tempos de observação calculados em diferentes unidades (dias, meses, trimestres, anos)
- DESFECHO: Variável binária para análise de sobrevivência
- TOPOGRUP_GRUPO: Agrupamento personalizado das topografias
- IDADE_ESTRATIFICADA: Categorização dinâmica da idade usando método de maxstat

Estas variáveis permitem realizar análises completas de sobrevivência (Kaplan-Meier), estimativas de hazard, e modelagem de Cox proporcional, além de fornecer filtros dinâmicos para exploração interativa dos dados oncológicos.

Para o pré-processamento os seguintes pacotes foram utilizados.

```
# Pré-processamento e manipulação de dados
library(foreign)      # Leitura de arquivos .dbf
library(dplyr)        # Manipulação de dados
library(lubridate)    # Manipulação de datas
library(data.table)   # Estrutura de dados eficiente
library(fst)          # Formato de arquivo rápido para armazenamento
library(purrr)        # Programação funcional
```

Script de pré-processamento.

```
## Aqui vamos filtrar as CID's que iremos utilizar

dados_cancer <- read.dbf("data/pacigeral.dbf") # disponível no classroom

# Neoplasias Urogenitais, Urinárias, Olho e Sistema Nervoso Central,
# Endócrinas e Secundárias/Mal Definidas

# C50 a C80 (incluindo todas as CIDs neste intervalo)

grupo_cids <- paste0("C",50:80)
grupo_cids
## Filtrando cids
dados_cancer_filtrado1 <- dados_cancer |>
  filter(TOPOGRUP %in% grupo_cids)

## Filtrando variáveis
dados_cancer_filtrado2 <- dados_cancer_filtrado1 |>
  select(
    TOPOGRUP, #Grupo da topografia (Seleção)
    SEXO, #Sexo do paciente (KM)
    IDADE, #Candidata a maxstat
    FAIXAETAR, #Faixa etaria do paciente (KM)
    EC, #Estadio clinico (KM)

    #Candidatas para o uso do maxstat
    CONSDIAG, #Diferença em dias entre as datas de consulta o diagnostico
    TRATCONS, #Diferença em dias entre as datas de consulta e tratamento
    DIAGTRAT, #Diferença em dias entra as datas de tratamento e diagnostico
```

```

DTCONSULT, #Data da 1a consulta
DTDIAG, #Data do diagnostico

DTTRAT, #Data de inicio do tratamento (Só para checar não entra na conta)
NAOTRAT, #Código da razão para não realização do tratamento
        #(Só para checar não entra na conta)

TRATAMENTO, #Código de combinação dos tratamentos realizados

DTULTINFO, #Data da ultima informacao do paciente

#Sobre desfecho
ULTINFO, #Ultima informacao do paciente
) |>

```

```

mutate(
  TOPOGRUP_GRUPO = factor(
    case_when(
      TOPOGRUP == "C50" ~ "C50 Mama",
      TOPOGRUP %in% c("C51", "C52", "C53", "C54", "C55", "C56", "C57", "C58") ~
        "C51-C58 Órgãos genitais femininos",
      TOPOGRUP %in% c("C60", "C61", "C62", "C63") ~
        "C60-C63 Órgãos genitais masculinos",
      TOPOGRUP %in% c("C64", "C65", "C66", "C67", "C68") ~
        "C64-C68 Trato urinário",
      TOPOGRUP %in% c("C69", "C70", "C71", "C72") ~
        "C69-C72 Olho, cérebro e outras partes do SNC",
      TOPOGRUP %in% c("C73", "C74", "C75") ~
        "C73-C75 Tiróide e outras glândulas",
      TOPOGRUP == "C76" ~
        "C76 Out. localizações e localizações mal definidas",
      TOPOGRUP == "C77" ~
        "C77 Linfonodos",
      TOPOGRUP == "C80" ~
        "C80 Localização primária desconhecida",
    )),

  SEXO = factor(
    case_when(
      SEXO == 1 ~ "Masculino",
      SEXO == 2 ~ "Feminino"
    )),

  FAIXAETAR = factor(
    case_when(
      FAIXAETAR == "00-09" ~ "0 a 9 anos",
      FAIXAETAR == "10-19" ~ "10 a 19 anos",
      FAIXAETAR == "20-29" ~ "20 a 29 anos",
      FAIXAETAR == "30-39" ~ "30 a 39 anos",
      FAIXAETAR == "40-49" ~ "40 a 49 anos",
      FAIXAETAR == "50-59" ~ "50 a 59 anos",
      FAIXAETAR == "60-69" ~ "60 a 69 anos",
      FAIXAETAR == "70+" ~ "70 anos ou mais"
    )
  )
)

```

```

),
levels = c(
  "0 a 9 anos",
  "10 a 19 anos",
  "20 a 29 anos",
  "30 a 39 anos",
  "40 a 49 anos",
  "50 a 59 anos",
  "60 a 69 anos",
  "70 anos ou mais"
),
ordered = TRUE
),

DTULTINFO = dmy(as.character(DTULTINFO)),

#Tempo observado
TEMPO_OBS_DIAG_DIAS = as.numeric(DTULTINFO - DTDIAG),
TEMPO_OBS_CONSULT_DIAS = as.numeric(DTULTINFO - DTCONSULT),

TEMPO_OBS_DIAG_MESES = floor(as.numeric(DTULTINFO - DTDIAG) / 30) + 1,
TEMPO_OBS_CONSULT_MESES = floor(as.numeric(DTULTINFO - DTCONSULT) / 30) + 1,

TEMPO_OBS_DIAG_TRI = floor(as.numeric(DTULTINFO - DTDIAG) / 90) + 1,
TEMPO_OBS_CONSULT_TRI = floor(as.numeric(DTULTINFO - DTCONSULT) / 90) + 1,

TEMPO_OBS_DIAG_ANO = floor(as.numeric(DTULTINFO - DTDIAG) / 365) + 1,
TEMPO_OBS_CONSULT_ANO = floor(as.numeric(DTULTINFO - DTCONSULT) / 365) + 1,

#Tratamento
TRATAMENTO = factor(
  case_when(
    TRATAMENTO == "A" ~ "Cirurgia",
    TRATAMENTO == "B" ~ "Radioterapia",
    TRATAMENTO == "C" ~ "Quimio",
    TRATAMENTO == "D" ~ "Cirurgia + Radioterapia",
    TRATAMENTO == "E" ~ "Cirurgia + Quimio",
    TRATAMENTO == "F" ~ "Radioterapia + Quimio",
    TRATAMENTO == "G" ~ "Cirurgia + Radio + Quimio",
    TRATAMENTO == "H" ~ "Cirurgia + Radio + Quimio + Hormonio",
    TRATAMENTO == "I" ~ "Outras combinações de tratamento",
    TRATAMENTO == "J" ~ "Nenhum tratamento realizado"
  ),
  levels = c(
    "Cirurgia",
    "Radioterapia",
    "Quimio",
    "Cirurgia + Radioterapia",
    "Cirurgia + Quimio",
    "Radioterapia + Quimio",
    "Cirurgia + Radio + Quimio",
    "Cirurgia + Radio + Quimio + Hormonio",
    "Outras combinações de tratamento",
  )

```

```

    "Nenhum tratamento realizado"
  ),
  ordered = FALSE
  # Se TRUE, define como variável ordinal (hierarquia entre categorias)
),

#Estagio da doenca
GRUPO_EC = factor(
  case_when(
    EC %in% c("O", "OA", "OIS", "IS") ~ "Estágio 0",
    EC %in% c("I", "IA", "IA1", "IA2", "IB", "IB1", "IB2", "IC") ~ "Estágio I",
    EC %in% c("II", "IIA", "IIA1", "IIA2", "IIB", "IIC") ~ "Estágio II",
    EC %in% c("III", "IIIA", "IIIB", "IIIC", "IIIC1", "IIIC2") ~ "Estágio III",
    EC %in% c("IV", "IVA", "IVB", "IVC") ~ "Estágio IV",
    EC == "X" ~ "X",
    EC == "Y" ~ "Y"
  )),

# 1 - VIVO, COM CÂNCER
# 2 - VIVO, SOE
# 3 - ÓBITO POR CANCER
# 4 - ÓBITO POR OUTRAS CAUSAS, SOE

ULTINFO = factor(
  case_when(
    ULTINFO == 1 ~ "Vivo, com câncer",
    ULTINFO == 2 ~ "Vivo, sem outra especificação",
    ULTINFO == 3 ~ "Óbito por câncer",
    ULTINFO == 4 ~ "Óbito por outras causas, sem outra especificação"
  )),

DESFECHO = case_when(
  ULTINFO %in% c("Vivo, com câncer",
                 "Vivo, sem outra especificação",
                 "Óbito por outras causas, sem outra especificação") ~ "0",
  ULTINFO == "Óbito por câncer" ~ "1"
),
NAOTRAT = as.factor(NAOTRAT),
DESFECHO = as.numeric(DESFECHO)
)

## Salvando como data.table + FST
dados_cancer_dt <- as.data.table(dados_cancer_filtrado2)
write_fst(dados_cancer_dt, "data/dados_cancer_filtrado.fst")

```

3.1 Construção do painel

Para a construção do painel os seguintes pacotes foram utilizados.

```

# Construção do painel Shiny
library(shiny)           # Framework principal
library(shinydashboard) # Layout de dashboard
library(shinycssloaders)# Indicadores de carregamento

```

```
library(shinyWidgets)  # Widgets adicionais

# Visualização e análise
library(highcharter)   # Gráficos interativos
library(survival)      # Análise de sobrevivência
library(survminer)     # Visualização de análise de sobrevivência
library(muhaz)         # Estimção de hazard
library(broom)         # Tidy de modelos estatísticos
library(DT)           # Tabelas interativas
```

O código-fonte completo do painel está disponível no repositório GitHub: https://github.com/EsleyCaminhas/painel_sobrevivencia

3.1.1 Implementação do ponto de corte para a variável idade

Dentro do painel, foi implementada uma funcionalidade para determinar automaticamente o ponto de corte ótimo da idade usando o método de maxstat, que se adapta dinamicamente às seleções de tempo do usuário:

```
# 1. Criar uma expressão reativa que depende das seleções de tempo do usuário
# Usaremos os inputs da aba Kaplan-Meier (input$Tempo_int e input$len_tempo)
# para controlar o cálculo
dados_cancer_reativo <- reactive({

  # Garante que os inputs de tempo existem antes de prosseguir
  req(input$Tempo_int, input$len_tempo)

  # Cria o nome da coluna de tempo dinamicamente com base na seleção do usuário
  tempo_selecionado <- paste0("TEMPO_OBS_", input$Tempo_int, "_", input$len_tempo)

  # Filtra o data.frame para garantir que o tempo seja maior que zero na escala
  # selecionada
  dados_filtrados_tempo <- dados_cancer_base |>
    filter(.data[[tempo_selecionado]] > 0)

  # 2. Encontrar o ponto de corte ótimo para a idade usando o tempo dinâmico
  res_cutpoint <- surv_cutpoint(
    data = dados_filtrados_tempo,
    time = tempo_selecionado, # Usa a coluna de tempo dinâmica
    event = "DESFECHO",
    variables = "IDADE",
    minprop = 0.2
  )

  # 3. Extrair o valor numérico do ponto de corte
  ponto_de_corte <- res_cutpoint$cutpoint$cutpoint

  # 4. Criar as etiquetas descritivas
  label_menor <- paste0("Idade menor que ", ponto_de_corte, " anos")
  label_maior <- paste0("Idade maior ou igual a ", ponto_de_corte, " anos")

  # 5. Adicionar a nova coluna e renomear os níveis do fator ao data.frame
  # filtrado
```

```

dados_com_idade_estratificada <- dados_filtrados_tempo |>
  mutate(
    IDADE_ESTRATIFICADA = surv_categorize(res_cutpoint)$IDADE,
    IDADE_ESTRATIFICADA = recode_factor(IDADE_ESTRATIFICADA,
                                         "low" = label_menor,
                                         "high" = label_maior)
  )

  return(dados_com_idade_estratificada)
})

```

Esta implementação permite que o ponto de corte da idade seja determinado dinamicamente com base na unidade de tempo selecionada pelo usuário (dias, meses, trimestres ou anos), garantindo que a estratificação seja sempre otimizada para a janela temporal em questão.

3.1.2 Dados implausíveis

Durante a criação da variável TEMPO_OBS_DIAG_MESES, foram observados valores negativos, indicando inconsistências temporais nos dados (como datas de última informação anteriores às datas de diagnóstico). Esses registros foram removidos para garantir a qualidade da análise:

```

dados_cancer_base <- read_fst("data/dados_cancer_filtrado.fst",
                             as.data.table = TRUE) |>
  filter(TEMPO_OBS_DIAG_MESES > 0)

```